Visualisierung mit Python - interaktive Beispiele

von Patrick Senti

Themen

- pandas
- seaborn
- plotly

Interaktive Ausführung mit plots-interaktiv.ipynb

Quelle:
https://gist.github.com/miraculixx/6d9994d060e7a200f120f91b8b459c41

In [1…

```
# libraries importieren
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import plotly.express as px
import plotly.io as pio
import warnings
warnings.filterwarnings('ignore') # Warnungen ignorieren, d
sns.set_theme() # wir verwenden das Seaborn-Theme für alle
plt.rc('figure', figsize=(8, 4)) # default fig size matplot
pio.renderers.default = 'jupyterlab' # enable for pdf expor
```

pandas

- pandas ist eine Python Library für Datenverarbeitung, -Analyse und -Manipulation

Referenzen

- https://pandas.pydata.org
- https://pandas.pydata.org/Pandas_Cheat_Sheet.pdf
- https://github.com/tommyod/awesome-pandas

In [1…

```
from io import StringIO
daten = """
land,umsatz
Schweiz,1000
```

```
Deutschland,9000
USA,15000
"""
in_memory_file = StringIO(daten)
df_umsatz = pd.read_csv(in_memory_file)
df_umsatz
```

Out[1…

	land	umsatz
0	Schweiz	1000
1	Deutschland	9000
2	USA	15000

In [1…

```
df_meteo = pd.read_csv('./data/wetter_monthly.csv')
df_meteo
```

Out[1…

	month	tavg	tmin	tmax	prcp	snow	
0	01-Jan	1.683871	-0.819355	4.658065	1.274194	4.838710	169.4
1	02-Feb	4.471429	1.157143	8.457143	1.942857	0.357143	201.8
2	03-Mar	7.229032	2.200000	13.067742	0.854839	0.000000	83.0
3	04-Apr	9.153333	4.593333	14.276667	2.840000	1.666667	149.4
4	05-May	15.961290	11.461290	21.151613	2.341935	0.000000	139.3
5	06-Jun	19.506667	14.256667	25.270000	4.220000	0.000000	158.2
6	07-Jul	21.193548	15.641935	27.406452	1.445161	0.000000	139.8
7	08-Aug	20.322581	15.322581	26.500000	2.422581	0.000000	106.3
8	09-Sep	14.236667	10.723333	18.586667	3.760000	0.000000	173.3
9	10-Oct	13.712903	10.567742	17.916129	2.238710	0.000000	145.8
10	11-Nov	7.250000	4.846667	9.966667	2.490000	0.000000	168.6
11	12-Dec	2.683871	0.654839	4.816129	2.912903	16.451613	158.5

Daten plotten, visuell darstellen

- Einen ersten einfachen Bar-Plot mit `df.plot.bar()` erstellen

- Den Bar-Plot gibt's auch in horizontaler Darstellung mit `df.plot.barh()`

In [1…
```
df_umsatz.plot.bar(x='land',
                   y='umsatz')
```

Out[1…
```
<Axes: xlabel='land'>
```

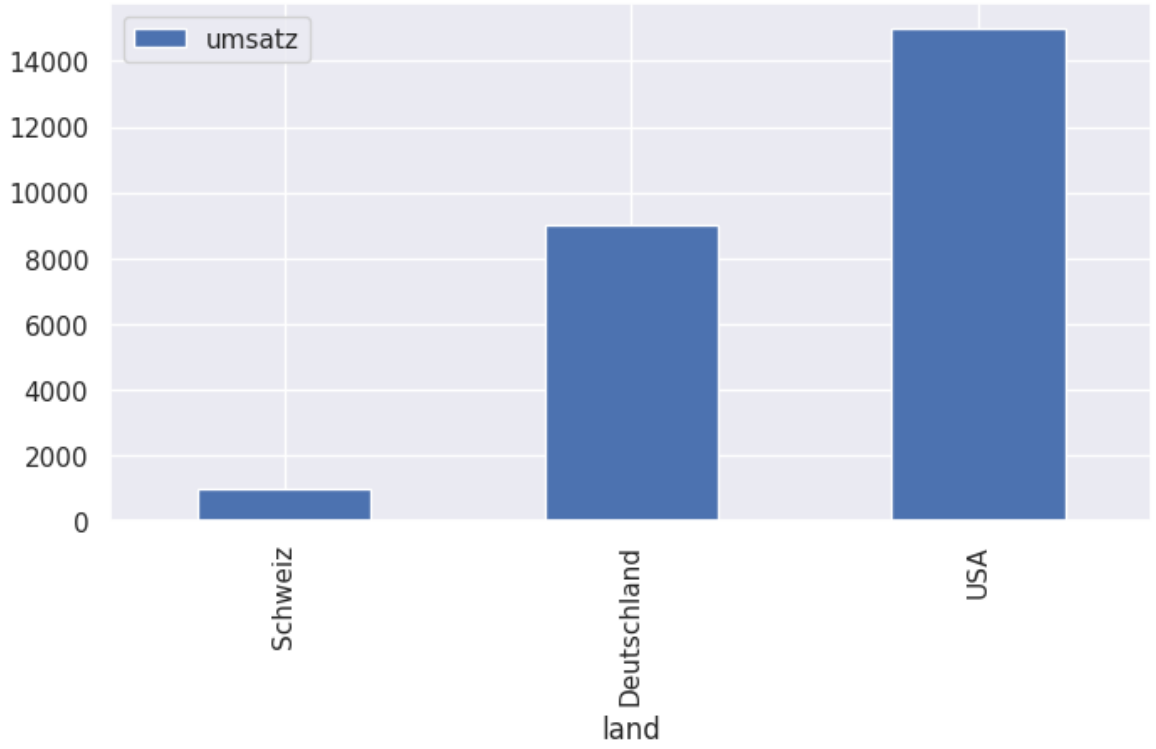

In [1…
```
# achtung, x= und y= behalten ihre semantische Bedeutung vo
# -- d.h. x= ist die Gruppierung, y= die Metrik
# -- dies obwohl die x und y Achse in der Darstellung verta
# -- das macht es einfacher von .bar() auf .barh() zu wechs
df_umsatz.plot.barh(x='land',
                    y='umsatz')
```

Out[1…
```
<Axes: ylabel='land'>
```

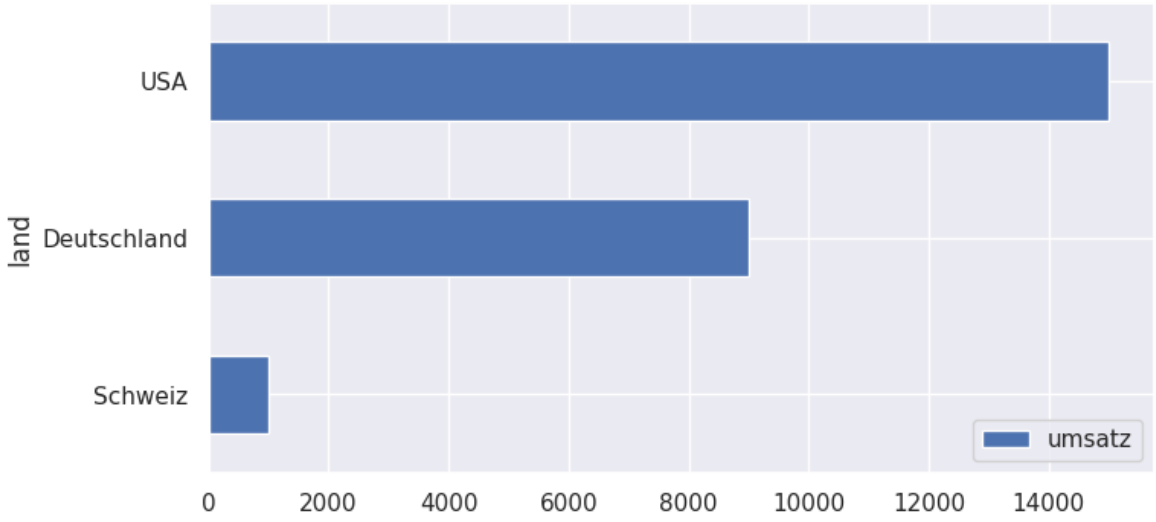

- Scatter Plots vergleichen viele Datenpunkte in zwei Dimensionen: `df.plot.scatter()`

In [1…
```
df_meteo.plot.scatter(x='tavg',
                      y='snow')
```

Out[1…
```
<Axes: xlabel='tavg', ylabel='snow'>
```

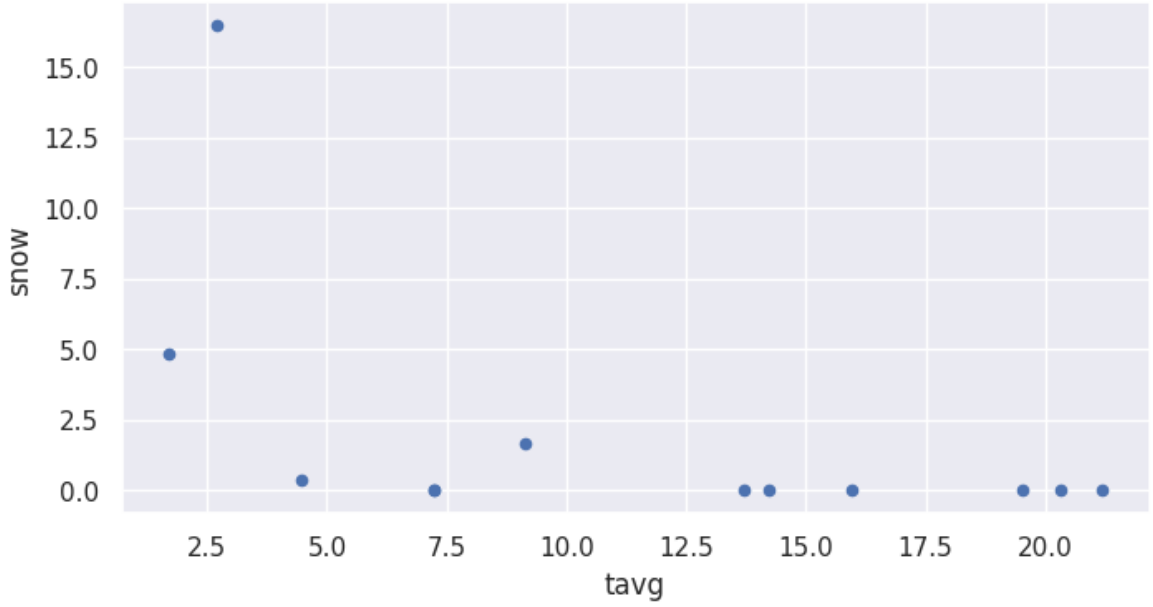

- Lineplots zeigen Entwicklungen über Zeit (oder andere ordinale Einteilungen)

In [1…
```
df_meteo.plot.line(x='month',
                   y=['tavg', 'tmin', 'tmax']) # NB. mehrer
```

Out[1…
```
<Axes: xlabel='month'>
```

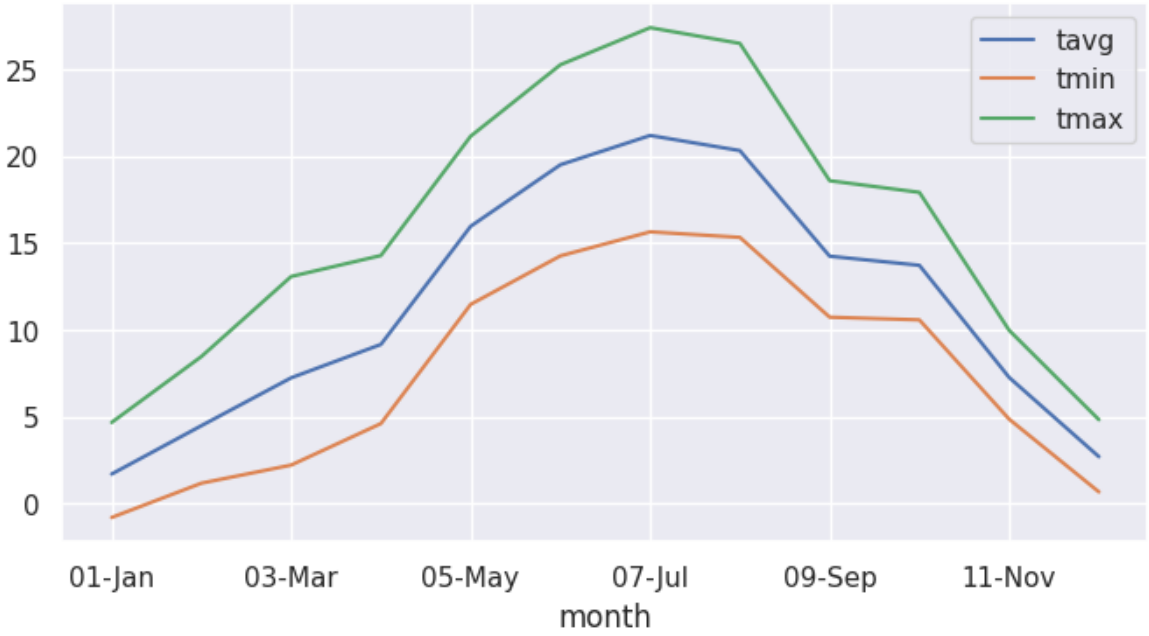

- Nächster Plot: Pie-Charts mit `df.plot.pie()`
- Ein Pie-Plot entspricht einer Aggregation einer Gruppe zu insgesamt 100%
- Wir müssen die Daten selbst gruppieren: mit `df.groupby()`

In [1…
```
(df_umsatz
 .groupby('land')
 .sum('umsatz')
 .plot.pie(y='umsatz'))
```

Out[1…
```
<Axes: ylabel='umsatz'>
```

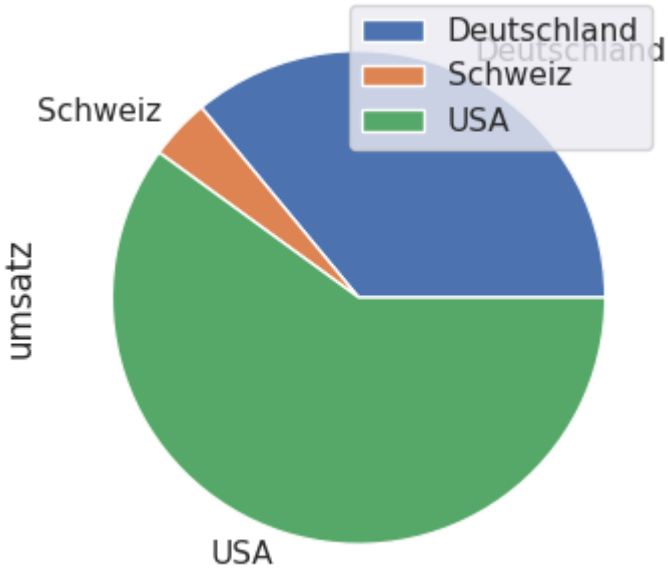

Der Pie Plot ist kaum lesenbar:

- die Prozent-Anteile sind nicht sichtbar => `.pie(..., autopct='%1.1f%%')`
- die Legende ist über dem Pie-Plot => `plt.legend()`
- die Beschriftung der Y Achse wirkt verwirrend => `plt.ylabel()`
- die Farbe und Fontgrösse ist nicht schön zu lesen => `.pie(..., fontsize=, textprops=)`
- weitere Parameter und Beispiele: https://matplotlib.org/stable/gallery/pie_and_polar_charts/pie_and_donut

In [1…
```
(df_umsatz
 .groupby('land')
 .sum('umsatz')
 .plot.pie(y='umsatz',
           autopct='%1.1f%%',
           fontsize=8,
```

```
            textprops={'color': 'white'},
           ))
plt.ylabel('')
plt.legend(loc='center right', # lower left/center/right
           bbox_to_anchor=(1.5, .5)) # (0,0) = unten links,
plt.show()
```

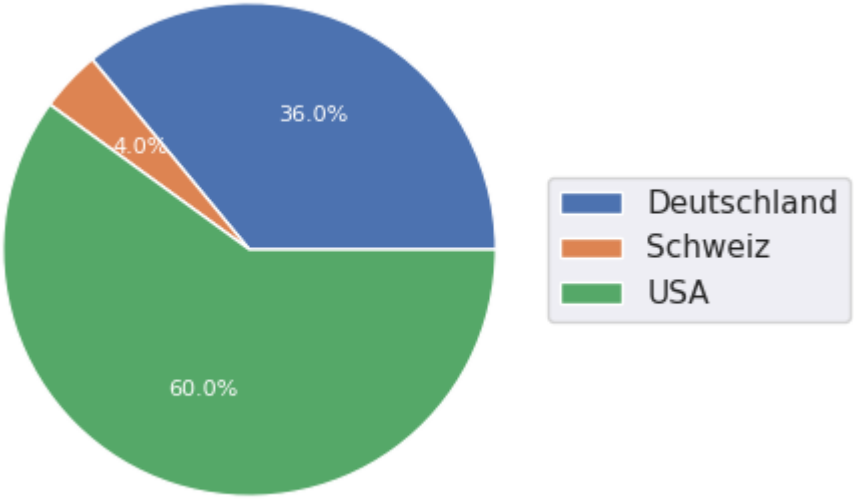

Beschriftung, Achsenskalierung

- Titel => `plt.title()` und `plt.suptitle()`
- Legende => `plt.legend()`
- X-Achse => `plt.xlabel()`
- Y-Achse => `plt.ylabel()`
- X-Achse Ticks => `plt.xticks()`
- Marker => `plot.line(..., marker=)`

In [1…

```
(df_meteo
 .plot.line(x='month',
            y=['tavg', 'tmin', 'tmax'],
            marker='.')
)
plt.suptitle('Wetterklima in Zürich')
plt.title('Temperatur im Jahresverlauf')
plt.xticks(ticks=range(0, 12),
           labels=['Jan', 'Feb', 'Mar', 'Apr', 'Mai', 'Jun'
                   'Jul', 'Aug', 'Sep', 'Oct', 'Nov', 'Dez'
          rotation=90)
plt.xlabel('Monat')
plt.ylabel('Temperatur C')
plt.legend(['Durchschnitt', 'Min', 'Max'],
```

```
            loc='lower center')
plt.show()
```

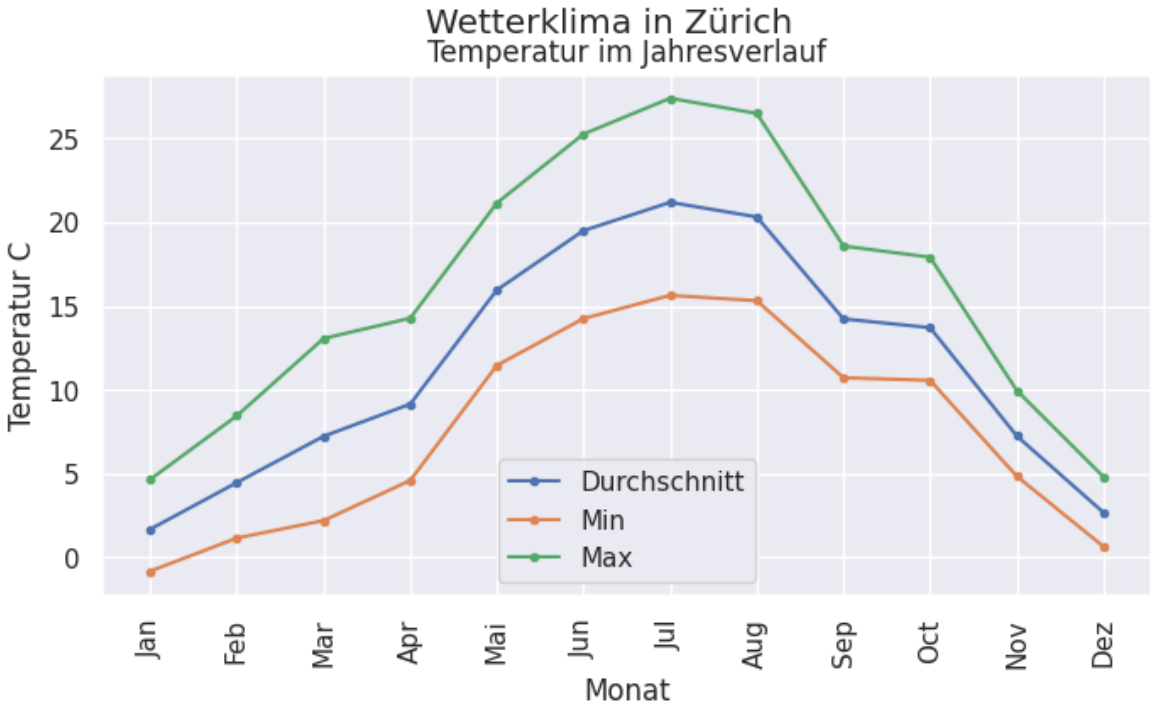

Subplots

- Manchmal möchten wir mehrere Plots zugleich erstellen => `plt.subplots()`
- Der gesamte Plot-Bereich nennt sich *Figure*, jeder einzelne Plot ist eine *Axis*, alle Plots zusammen heissen *Axes* (Mehrzahl)
- Die Plots werden mittels Angabe der jeweiligen Axis gezeichnet => `df.plot.line(..., ax=); df.plot.scatter(..., ax=)`
- Einige der `plt.*` Funktionen müssen explizit auf dem jeweiligen Plot bzw. Axis ausgeführt werden, und haben einen anderen Namen => z.B. `plt.title()` => `ax.set_title()`, `plt.xticks()` => `ax.set_xticks()` usw.

Weitere Informationen

- Detailliertes Tutorial dazu: https://realpython.com/python-matplotlib-guide/
- Referenz Figure: https://matplotlib.org/stable/api/_as_gen/matplotlib.pyplot.figure.html
- Referenz Axis: https://matplotlib.org/stable/api/axis_api.html#axis-label

In [1…

```
# subplots() gibt eine Figure und mehre Axis Objekte zurück
fig, axes = plt.subplots(nrows=1,
                         ncols=2,
                         figsize=(12, 4)) # (width, height)
print(f"fig: {fig}, axes: {axes} (n.B. zwei Elemente in axe
# in jeder *axis* (einzelnes Element in axes) platzieren wi
ax1, ax2 = axes
# -- suptitle definiert den Gesamttitle über alle Plots
plt.suptitle('Umsatz und Wetter')
# -- alle weiteren Einstellungen erfolgen pro axis (ax1, ax
# -- erster Plot:
df_umsatz.plot.bar(x='land',
                   y='umsatz',
                   ax=ax1)
ax1.set_title('Umsatz') # plt.title() => ax1.set_title()
ax1.set_xticklabels(ax1.get_xticklabels(), # plt.xticks => 
                    rotation=25)
# -- zweiter Plot:
df_meteo.plot.scatter(x='tavg',
                      y='snow',
                      ax=ax2)
ax2.set_title('Wetter') # plt.title() => ax2.set_title()
# plot insgesamt anzeigen
plt.show()
```

```
fig: Figure(1200x400), axes: [<Axes: > <Axes: >] (n.B. zwei
Elemente in axes)
```

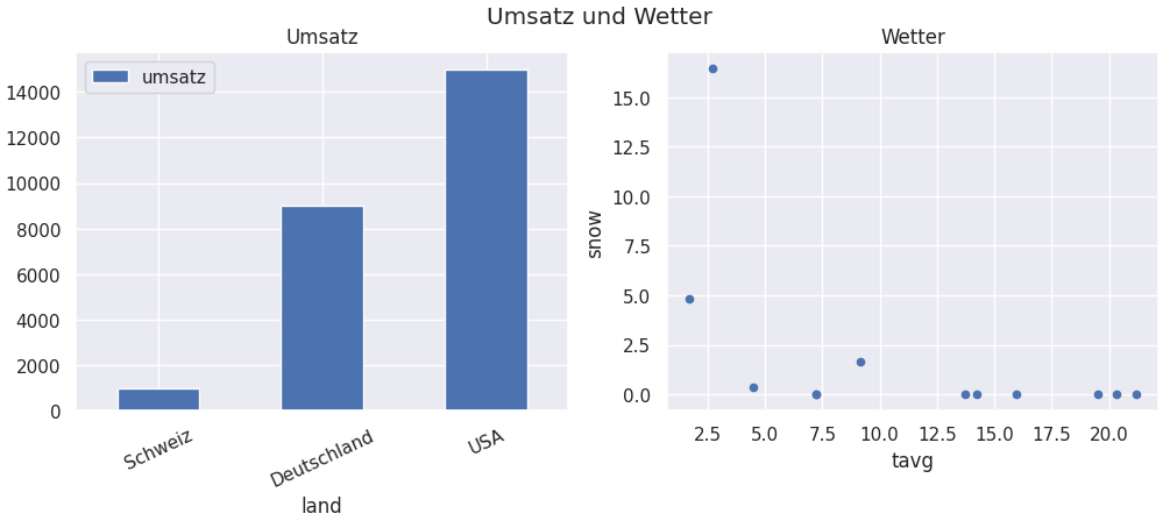

Wide Format, Long Format

- pandas bevorzugt Wide Format => pro Variable eine Spalte
- oft liegen Daten als Long Format vor => pro Zeile ein Wert, die Variable wird in einer Spalte angegeben
- Transformation von Long => Wide mit `pd.pivot_table()`

- Transformation von Wide => Long mit `pd.melt()`

In [1…

```
from io import StringIO
daten = """
land,jahr,umsatz
Schweiz,2022,800
Schweiz,2023,1000
Deutschland,2022,7500
Deutschland,2023,9000
USA,2022,14300
USA,2023,15000
"""
in_memory_file = StringIO(daten)
df_fy_umsatz = pd.read_csv(in_memory_file)
df_fy_umsatz
```

Out[1…

	land	jahr	umsatz
0	Schweiz	2022	800
1	Schweiz	2023	1000
2	Deutschland	2022	7500
3	Deutschland	2023	9000
4	USA	2022	14300
5	USA	2023	15000

In [1…

```
# Darstellung nach Gruppierung
# -- ok, aber nicht so schön
(df_fy_umsatz
 .groupby(['jahr', 'land'])
 .sum('umsatz')
 .plot.bar(y='umsatz'))
plt.show()
```

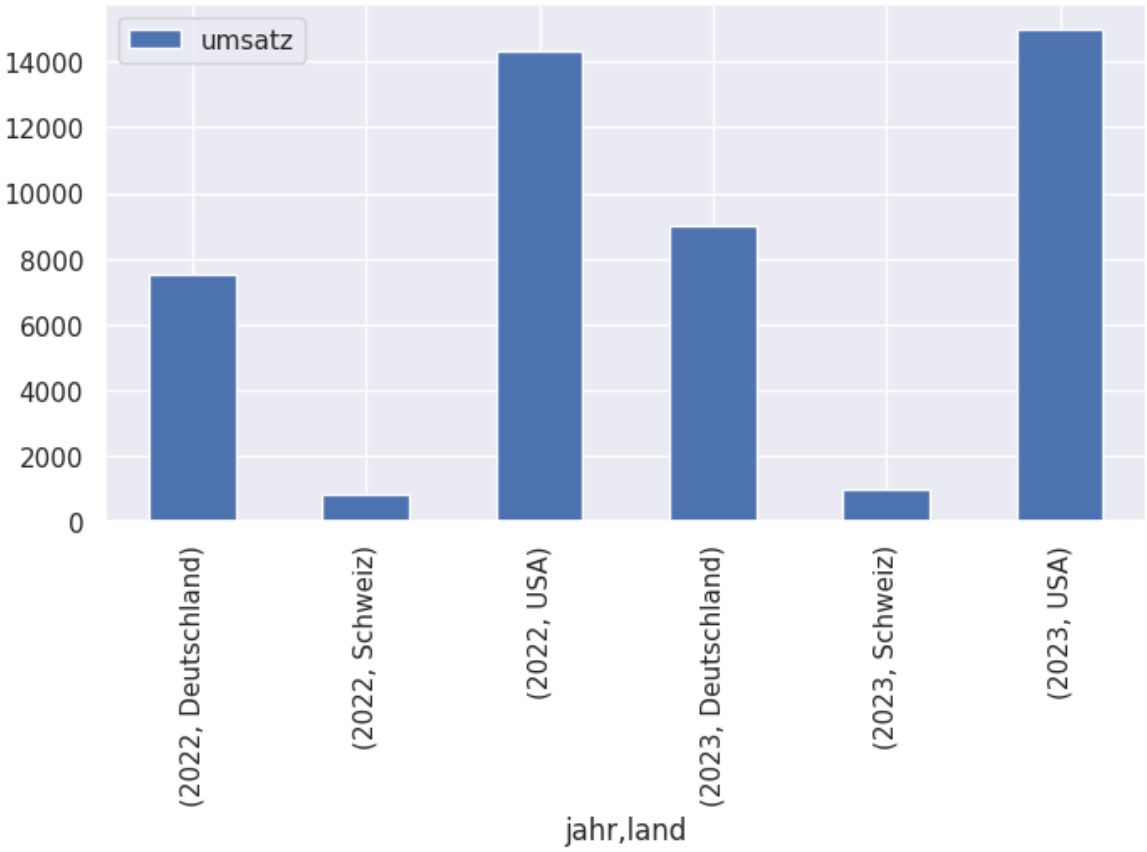

In [1…
```
# besser: Transformation in Wide Format
# -- Ziel: pro Land eine eigene Spalte
df_fy_umsatz_w = (pd.pivot_table(df_fy_umsatz,
                                 index='jahr', # erste Grupp
                                 columns='land', # zwei Grup
                                 values='umsatz', # Aggregat
                                 aggfunc='sum') # Aggregatio
                  .reset_index()) # Indizierung nach Land a
df_fy_umsatz_w
```

Out[1…

land	jahr	Deutschland	Schweiz	USA
0	2022	7500	800	14300
1	2023	9000	1000	15000

In [1…
```
# so klappt's
df_fy_umsatz_w.plot.bar(x='jahr',
                        y=['Schweiz', 'Deutschland', 'USA']
plt.legend(loc='center right', # lower left/center/right
           bbox_to_anchor=(1.4, .5)) # (0,0) = unten links,
plt.show()
```

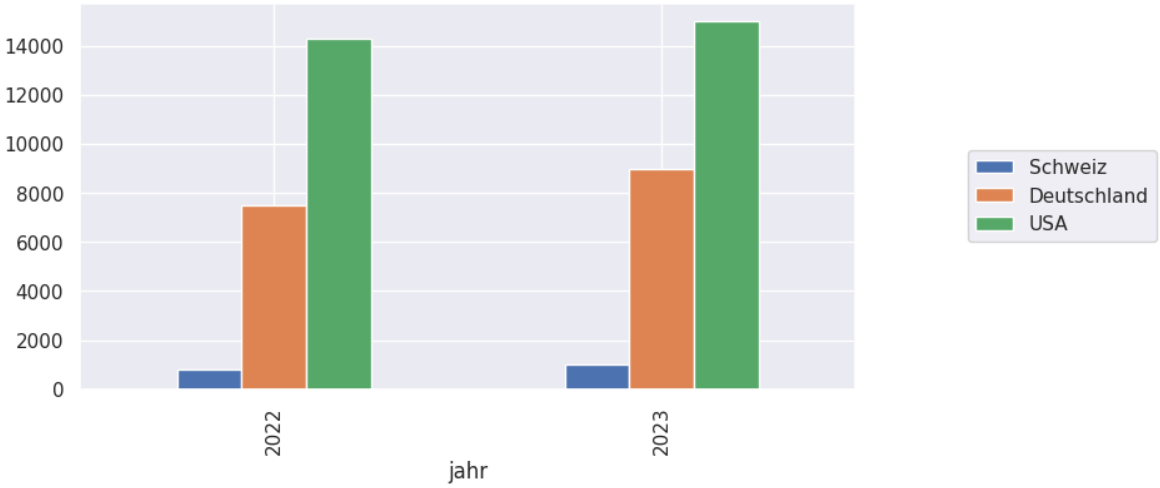

seaborn

- A library for statistical data visualization

Im Unterschied zu pandas kann seaborn:

- Daten automatisch aggregieren, um statistische Plots zu erstellen
- Mehrere Plots auf einmal erzeugen (das kann pandas zwar mit groupby() ebenfalls, seaborn ist jedoch einfacher und umfangreicher)
- Statistische Tests durchführen und im Plot einbetten (z.B. lineare Regression)

Seaborn bietet unterschiedliche Funktionen:

- sog. *Figure level* => erstellen ein oder mehrere Plots mit einem Befehl (z.B. nach Gruppierung)
- sog. *Axes level* => erstellen einen bestimmten Plot-Typ

Beide Funktionstypen können statistische Tests durchführen.

Referenzen

- https://seaborn.pydata.org/tutorial.html

Eine erster seaborn Plot: Relational Plot

- Zwei oder mehr Variablen vergleichen => `sns.relplot()`
- Erstellt Scatterplots oder Lineplots => `sns.relplot(..., kind='scatter|line')`
- Detailliertes Tutorial: https://seaborn.pydata.org/tutorial/relational.html

In [1…
```
# Import seaborn
import seaborn as sns

# Load an example dataset
tips = sns.load_dataset("tips")
# Create a visualization
sns.relplot(
    data=tips,
    x="total_bill",
    y="tip",
    col="time", # subplots nach Zeit (Lunch, Dinner)
    hue="smoker", # Farbe nach Smoker Status (Yes, No)
    style="smoker", # Marker nach  Smoker Status (Yes, No)
    size="size", # Grösse der Punkte nach Anzahl Gäste (1-6
)
```

Out[1…
```
<seaborn.axisgrid.FacetGrid at 0x7f19fe9b7be0>
```

Verteilungen mit seaborn

- Verteilungen darstellen => `sns.displot()`
- kann mehrere Plots auf einmal erzeugen => `sns.displot(..., col=)`
- kann Histogramme oder Kernel-Verteilungen darstellen => `sns.displot(..., kind='hist|kde')`
- kann mehrere Verteilungen auf einmal darstellen => `sns.displot(..., hue='column')`
- Detailliertes Tutorial: https://seaborn.pydata.org/tutorial/distributions.html#

In [1…
```
penguins = sns.load_dataset("penguins")
sns.displot(penguins,
```

```
            x="flipper_length_mm",
            kind='hist', # implizit "hist", versuche mit "k
            col="sex") # pro Geschlecht ein Plot (Male, Fem
```

Out[1…

```
<seaborn.axisgrid.FacetGrid at 0x7f19f30de560>
```

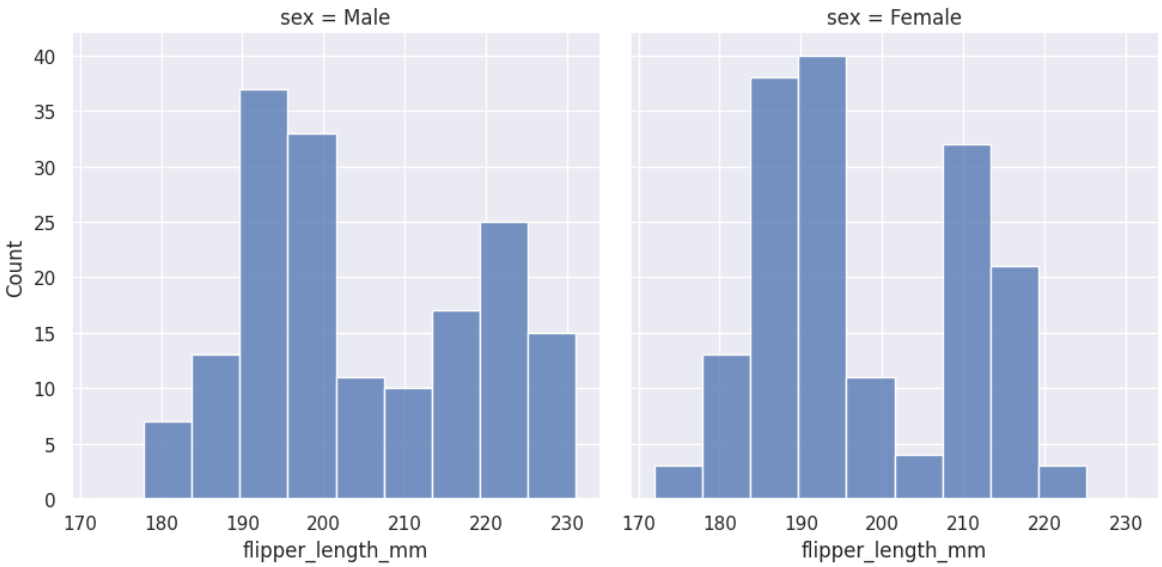

In [1…

```
sns.displot(penguins,
            x="flipper_length_mm",
            hue="species",
            kind="kde")
```

Out[1…

```
<seaborn.axisgrid.FacetGrid at 0x7f19f1cf09a0>
```

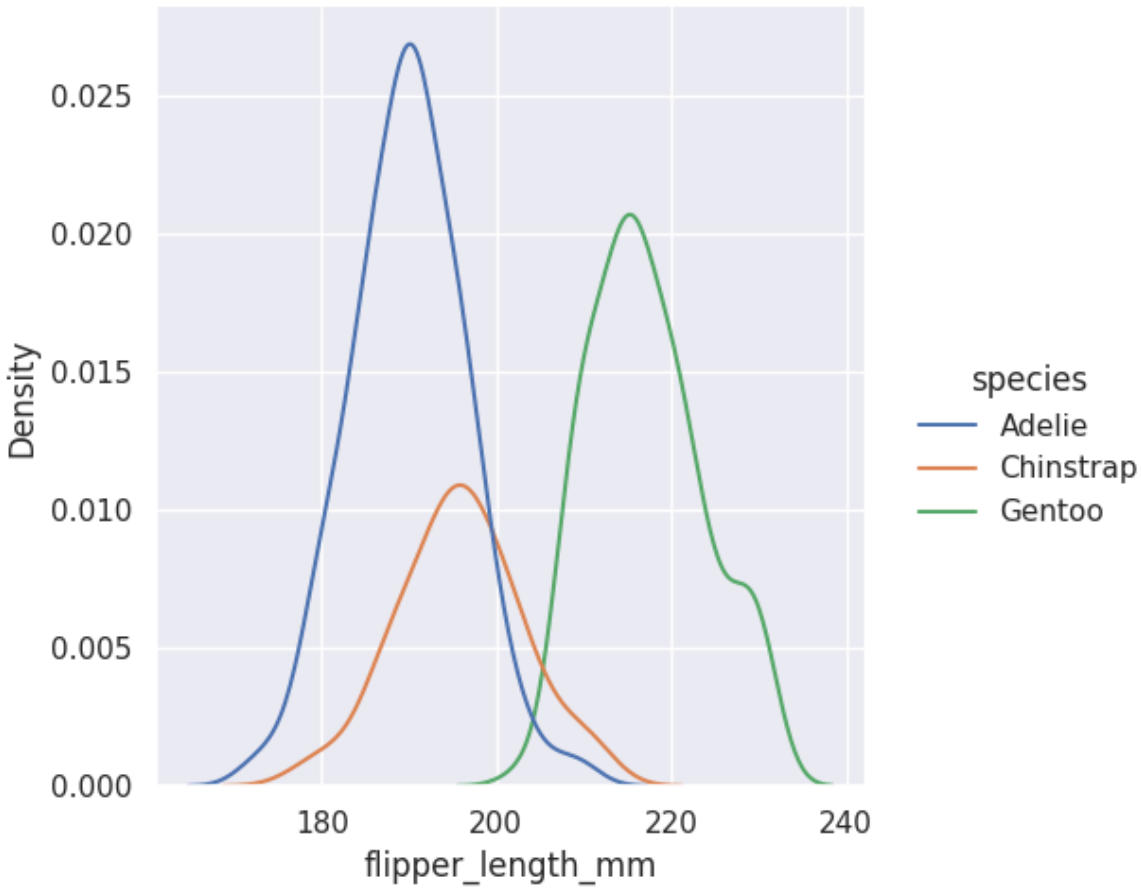

Kategorische (gruppierte) Daten mit seaborn

- Vergleiche mehrerer Gruppen, z.B. mit einem Scatterplot => `sns.catplot()`
- Auch für (etwas) grössere Datenmengen geeignet => `sns.catplot(..., jitter=True|False)`
- Swarmplots: manchmal sind Scatterplots, sogar mit Jitter, zu wenig detailliert => `sns.catplot(..., kind='swarm')

In [1…

```
tips = sns.load_dataset("tips")
sns.catplot(data=tips,
            x="day",
            y="total_bill",
            hue="sex", # einfärben der Punkte
            jitter=True) # verschiebt die einzelnen Marker
```

Out[1…

```
<seaborn.axisgrid.FacetGrid at 0x7f19fcf916f0>
```

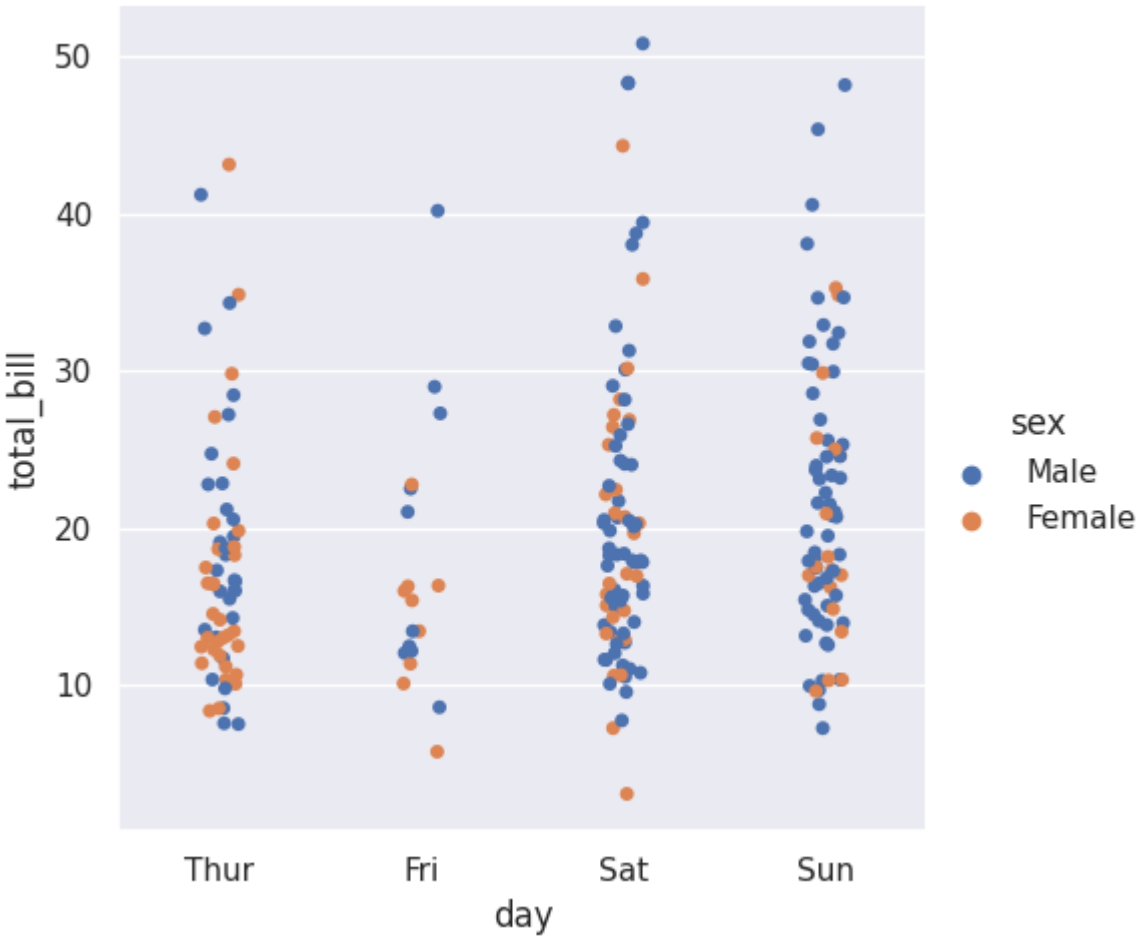

In [1…

```
tips = sns.load_dataset("tips")
sns.catplot(data=tips,
            x="day",
```

```
            y="total_bill",
            hue="sex", # einfärben der Punkte
            kind="swarm") # verschiebt die einzelnen Marker
```

Out[1…] <seaborn.axisgrid.FacetGrid at 0x7f19f114dc00>

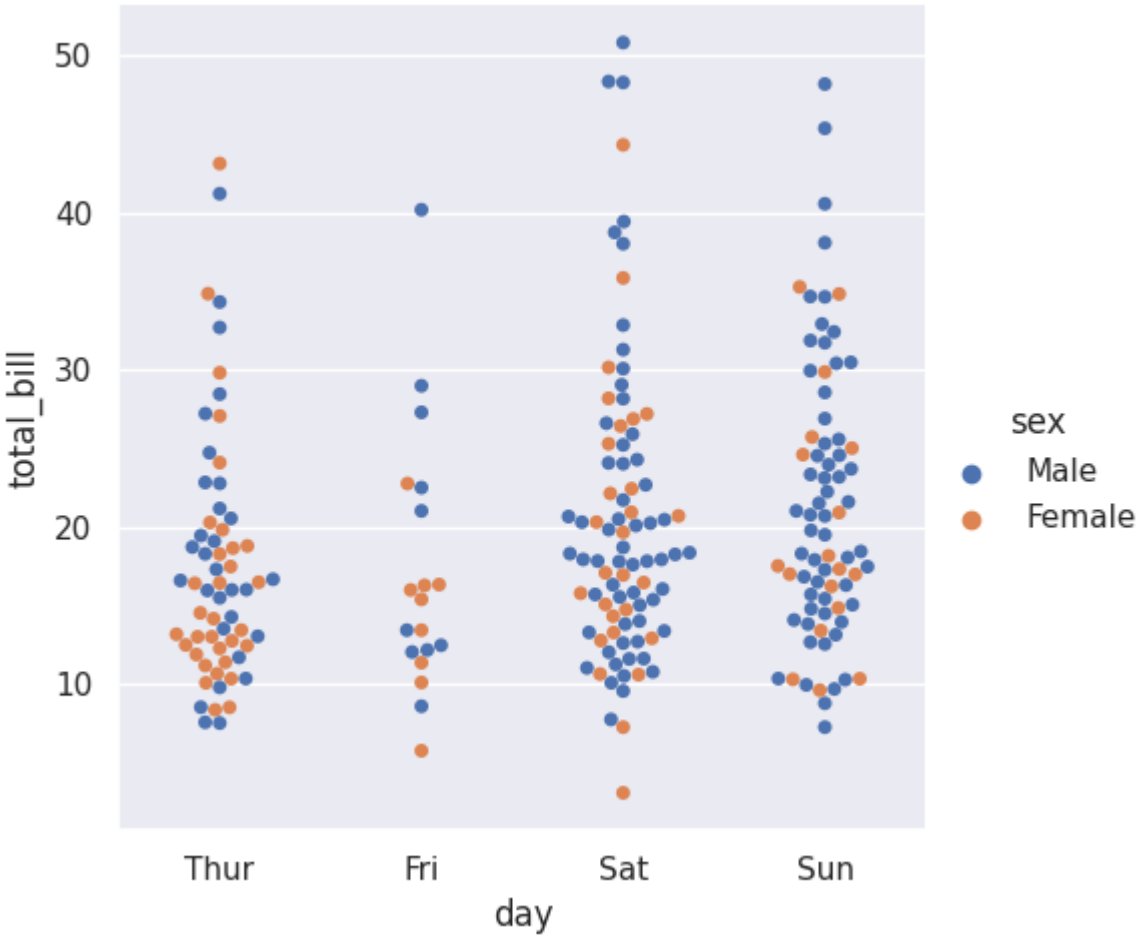

- Verteilungen mit Boxplot => `sns.catplot(..., kind='box')`
- Gruppierung innerhalb eines Plots => `sns.catplot(..., hue='column')`
- Pro Gruppe ein Plot => `sns.catplot(..., col='column')`

In [1…]
```
sns.catplot(data=tips,
            x="day",
            y="total_bill",
            hue='smoker', # Gruppierung innerhalb von Tag
            kind="box")
```

Out[1…] <seaborn.axisgrid.FacetGrid at 0x7f19fc930940>

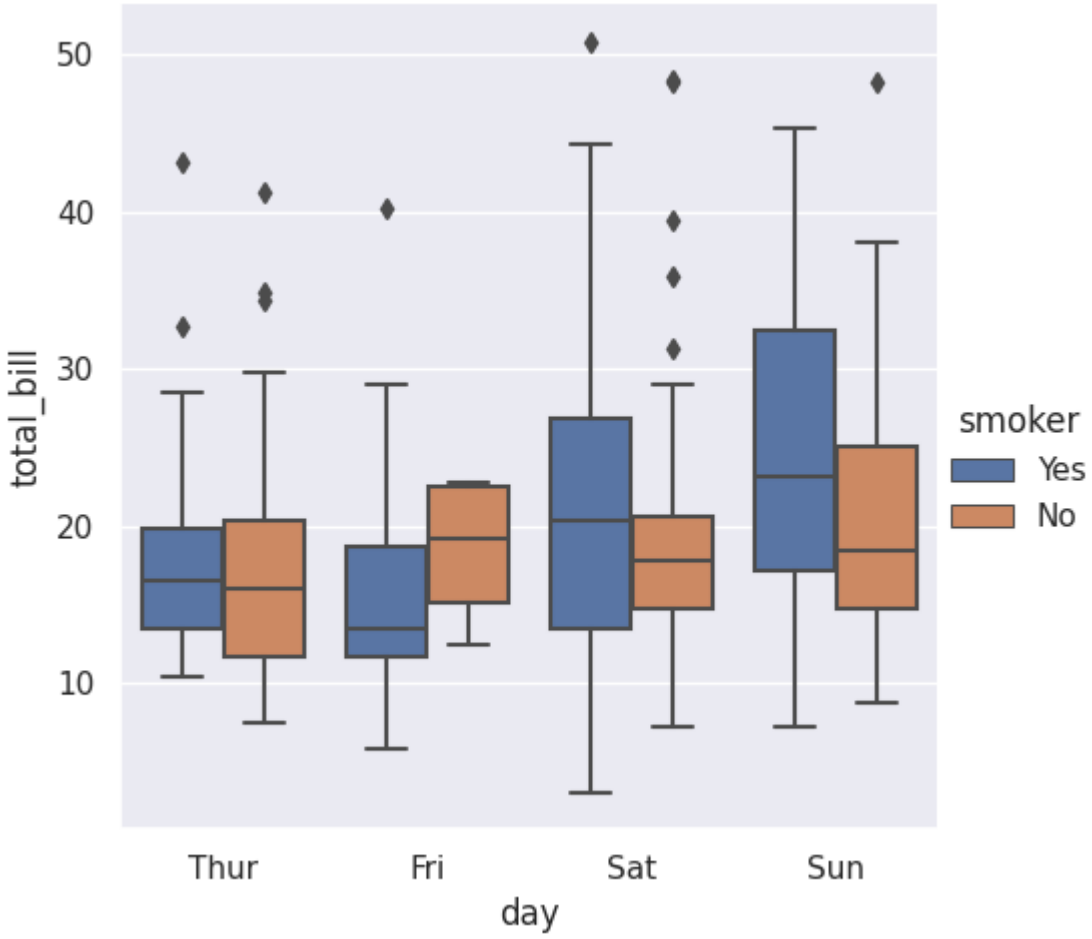

In [1…
```
sns.catplot(data=tips,
            x="day",
            y="total_bill",
            col='smoker', # mehrere Plots (analog relplot,
            kind="box")
```

Out[1… `<seaborn.axisgrid.FacetGrid at 0x7f19fc70d600>`

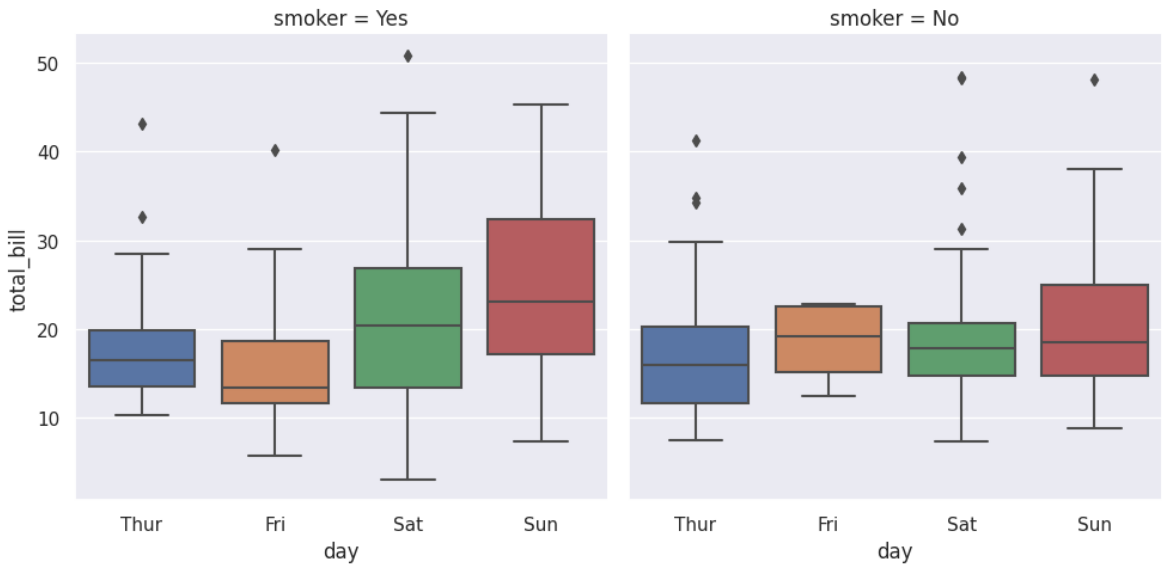

- Barplots mit Errorbar => `sns.catplot(..., kind='bar')`

- Berechnet den mean() pro Metrik, zeigt also Aggregation der Daten(!) => etwa `df.groupby().mean().plot.bar()` (nur schöner + einfacher)

In [1…
```
# ähnlich zu Pandas: `titanic.groupby(['sex', 'class']).mea
titanic = sns.load_dataset("titanic")
sns.catplot(data=titanic,
            x="sex",
            y="age",
            hue="class", # Farbe
            ci=95, # confidence interval für Errorbar (vers
            kind="bar") #
```

Out[1…
```
<seaborn.axisgrid.FacetGrid at 0x7f19f0ec3310>
```

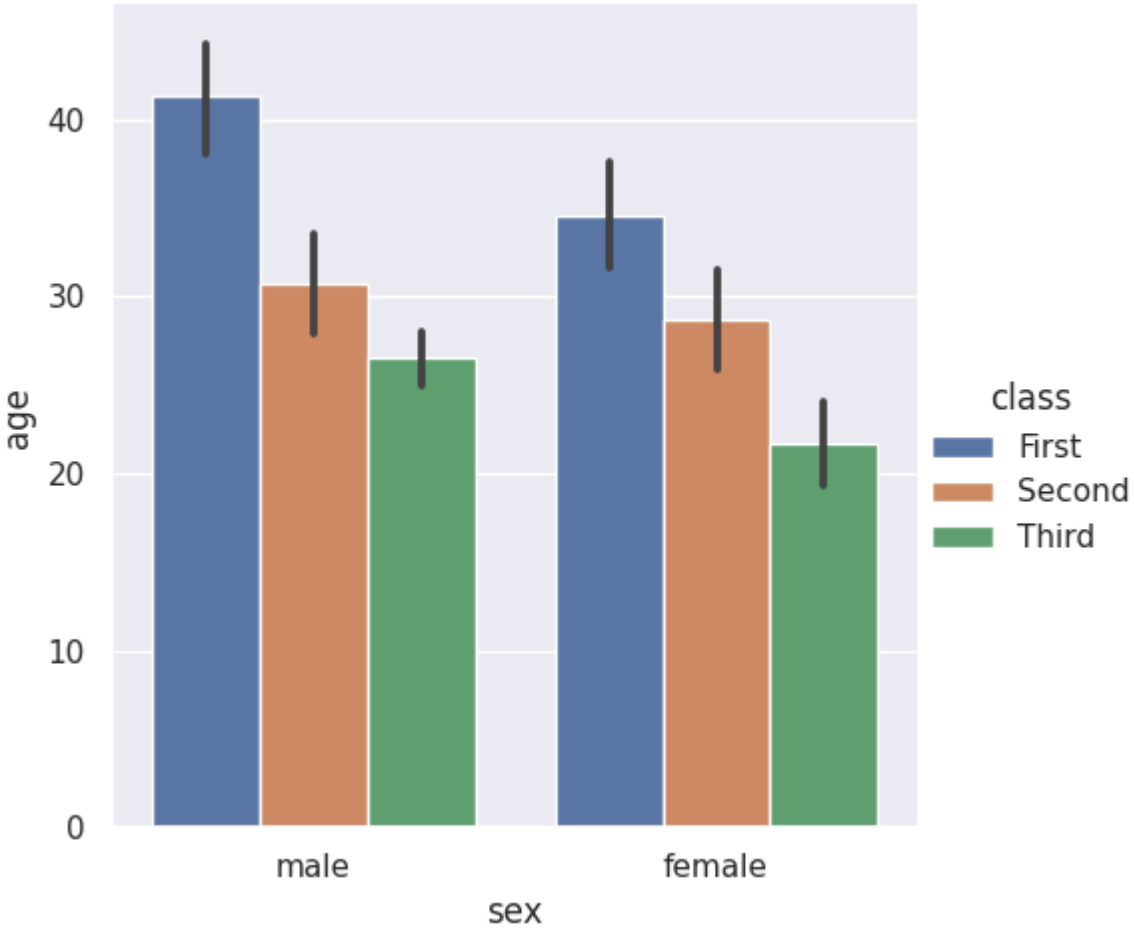

Plotly

- Library für interaktive Plots

Plotly bietet verschiende Funktionen an

- *Figure* => umfangreiche Detailfunktionen als Basis für Express => ähnlich wie Matplotlib für Pandas und Seaborn die Grundlage ist

- *Express* => einfache Funktionen => damit arbeiten wir

Referenzen

- Express: https://plotly.com/python/plotly-express/
- Figure: https://plotly.com/python/

Scatter plot mit Plotly Express

In [1…

```
import plotly.express as px

df = px.data.tips()
fig = px.scatter(df,
                 x="total_bill",
                 y="tip",
                 trendline="ols") # zeigt lineare Regressio
fig.show()
```

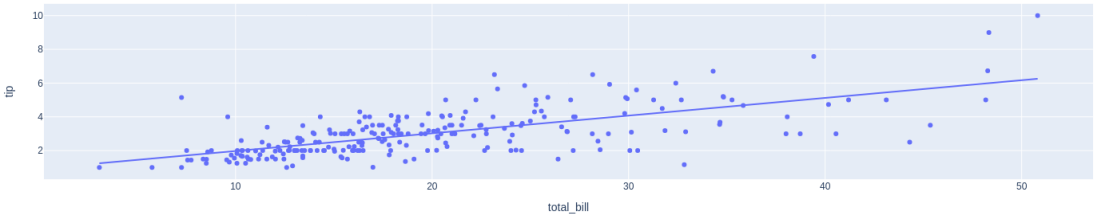

Line Plots

In [1…

```
import plotly.express as px
df = px.data.gapminder().query("continent == 'Oceania'")
fig = px.line(df, x='year', y='lifeExp', color='country')
fig.show()
```

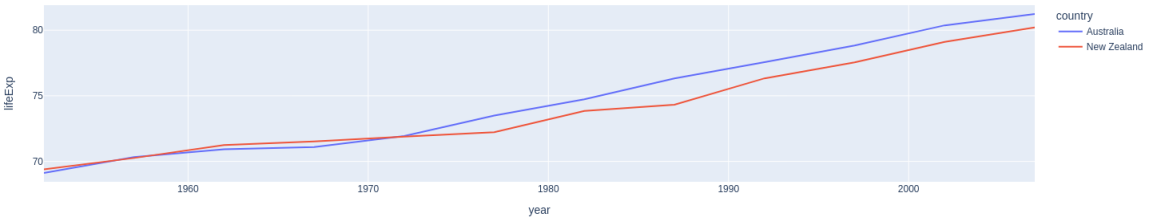

Pie Charts

- Gruppiert Daten automatisch => `px.pie(..., values=)`
- Einfache "Donut"-Plots => `px.pie(..., hole=)`

In [1…
```
import plotly.express as px
# This dataframe has 244 lines, but 4 distinct values for `
df = px.data.tips()
fig = px.pie(df,
             values='tip', # Column für 100%
             names='day') # Gruppierung
fig.show()
```

In [1…
```
import plotly.express as px
# This dataframe has 244 lines, but 4 distinct values for `
df = px.data.tips()
fig = px.pie(df,
             values='tip',
             names='day',
             hole=.3)
fig.show()
```

Interaktive Karten

In [1…
```
import plotly.express as px
df = (px.data.gapminder()
      .query("year == 2007"))
fig = px.scatter_geo(df,
                     locations="iso_alpha",
                     size="pop", # size of markers, "pop" i
                     )
fig.show()
```

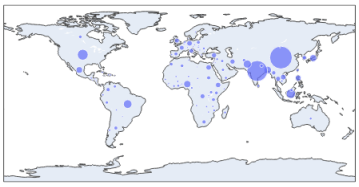

Quellenangaben

Für Daten- und Code Beispiele, soweit nicht vom Autor selbst:

- pandas: https://pandas.pydata.org/pandas-docs/version/2.1/user_guide/visualization.html, NumFocus Inc., BSD License
- seaborn: https://seaborn.pydata.org/tutorial/introduction.html, Michael Waskom, BSD License
- plotly: https://plotly.com/python/plotly-express/, Plotly Inc., MIT License
- Wetter-Daten: https://meteostat.net/de/, Christian Lamprecht, CC BY-NC 4.0 License